

INFORME ENTRENAMIENTO DE ALGORITMOS DE REGRESIÓN LINEAL Y REGRESIÓN POLINÓMICA

Samuel Serna Pulgarín

Carné:22136248

Facultad de Ingeniería, Instituto Tecnológico Metropolitano

Sistemas Inteligentes

Elizabeth Ospina Rojas

3 de mayo de 2025

Modelo de Regresión Lineal.

Descripción de la base de datos utilizada: tamaño, características, y variable que se busca predecir.

Tamaño: 395 filas y 33 columnas en el conjunto original (35 columnas tras la creación de características derivadas).

Características: Incluye variables sociodemográficas (edad, sexo, tamaño familiar, estado de los padres, educación/trabajo de los padres), académicas (tiempo de estudio, reprobación de asignaturas, apoyos educativos), personales/estilísticas (tiempo libre, salidas, consumo de alcohol entre semana y fin de semana, estado de salud, ausencias) y notas previas de evaluación (G1, G2).


Variable a predecir: G3 (calificación final de matemáticas del estudiante).

Técnicas de preprocesamiento aplicadas.

Tratamiento de Duplicados: Eliminación de registros idénticos en el conjunto de datos.

Imputación de Datos Faltantes: Relleno de valores nulos mediante la mediana de cada columna numérica para evitar distorsiones por valores atípicos.

Matriz de correlaciones y justificación de la selección de las características.



Justificación de selección: Se analizan los gráficos de dispersión de studytime, Dalc y Walc contra G3 para identificar patrones de dispersión y tendencia.

Tamaño del conjunto de train y del conjunto de test.

Conjunto Train: 316 muestras

Conjunto Test: 79 muestras

Métricas de desempeño en el conjunto de train y test y análisis de cada uno de sus resultados.

Error Medio Absoluto (MAE), y Coeficiente de Determinación R2:

Train -> MAE: 1.8119 | R2: 0.6870

Test -> MAE: 2.2053 | R2: 0.4703

Ecuación del modelo final obtenido.

$$G3 = (-1.9030) + (-0.0069Pedu) + (0.1439Alc) + (-0.3632failures) + (1.1139G1)$$

Modelo de Regresión Polinomial.

Descripción de la base de datos utilizada: tamaño, características, y variable que se busca predecir.

Tamaño: 930 filas y 15 columnas en el conjunto original.

Características:

Company Name (Nombre de la marca/fabricante)

Model Name (Modelo del dispositivo)

Mobile Weight (Peso en gramos)

RAM (Memoria RAM en GB)

Front Camera (Resolución de la cámara frontal en MP)

Back Camera (Resolución de la cámara principal/trasera en MP)

Processor (Procesador)

Battery Capacity (Capacidad de la batería en mAh)

Screen Size (Tamaño de la pantalla en pulgadas)

Launched Price (Pakistan) (Precio de lanzamiento en Pakistán, PKR)

Launched Price (India) (Precio de lanzamiento en India, INR)

Launched Price (China) (Precio de lanzamiento en China, CNY)

Launched Price (USA) (Precio de lanzamiento en Estados Unidos, USD)

Launched Price (Dubai) (Precio de lanzamiento en Dubái, AED)

Launched Year (Año de lanzamiento)

Marca_Num (Variable numérica codificada según la marca: Apple = 0.66, Samsung = 0.33, Otras = 0.25)

Variable a predecir: Launched Price (USA) (Precio de lanzamiento en Estados Unidos, USD).

Técnicas de preprocesamiento aplicadas.


Limpieza de Cadenas y Conversión Numérica: Limpieza de comas y caracteres no numéricos en precios y especificaciones técnicas (Mobile Weight, RAM, Front Camera, Back Camera, Battery Capacity, Screen Size y precios por país) para convertirlos a formato float.

Tratamiento de Duplicados: Eliminación de registros idénticos en el conjunto de datos.

Imputación de Datos Faltantes: Relleno de valores nulos mediante la mediana de cada columna numérica para evitar distorsiones por valores atípicos.

Ingeniería de Características: Generación de la columna Marca_Num para representar el valor perceptual de las marcas principales en el mercado.

Matriz de correlaciones y justificación de la selección de las características.



Justificación de selección: RAM y Marca_Num muestran la correlación directa lineal más alta con el precio. Aunque variables como Mobile Weight, Screen Size, Battery Capacity y las cámaras presentan correlaciones lineales bajas en crudo, se conservan en el modelo polinómico dado que sus combinaciones cuadráticas e interacciones explican variaciones complejas asociadas a teléfonos plegables y gamas altas.

Tamaño del conjunto de train y del conjunto de test.

Conjunto Train: 390 muestras

Conjunto Test: 98 muestras

Grado del polinomio definido para la regresión polinómica.

2.

Métricas de desempeño en el conjunto de train y test y análisis de cada uno de sus resultados.

Error Medio Absoluto (MAE), y Coeficiente de Determinación R2:

Train: R2: 0.6887 | MSE: 54835.7185 | MAE: \$234.17 USD

Test: R2: 0.6618 | MSE: 83706.0504 | MAE: \$289.32 USD

Ecuación del modelo final obtenido.

$$\begin{aligned} y = & -2164.5696 + 38.2916X_1 + 0.3440X_2 + 0.7807X_3 - 226.3199X_4 + 36.4971X_5 \\ & - 3.9658X_6 + 3620.3041X_7 - 0.0665X_1^2 - 0.0598X_1X_2 - 0.0275X_1X_3 \\ & + 35.1342X_1X_4 - 2.3732X_1X_5 - 0.2895X_1X_6 + 45.1571X_1X_7 + 0.0022X_2^2 \\ & + 0.0030X_2X_3 - 3.3780X_2X_4 + 0.2197X_2X_5 + 0.0390X_2X_6 + 23.0074X_2X_7 \\ & + 0.0001X_3^2 - 0.3134X_3X_4 + 0.0064X_3X_5 - 0.0009X_3X_6 - 0.7685X_3X_7 \\ & + 200.7316X_4^2 - 14.4860X_4X_5 - 1.1627X_4X_6 - 535.2232X_4X_7 + 0.3149X_5^2 \\ & + 0.1309X_5X_6 - 69.1218X_5X_7 + 0.0128X_6^2 + 19.5757X_6X_7 - 686.6436X_7^2 \end{aligned}$$